

第十五届「挑战杯」中国大学生创业计划竞赛

揭榜挂帅擂台赛 • 领域知识个性化生成与多智能体协同决策系统研究
(XH-202630)

集 智

——面向多智能体协同的领域知识个性化学习资源生成系统

作品设计实现方案

参赛团队：集智团队

二〇二六年九月

目 录

摘要	3
第一章 从题目要求出发：我们究竟要解决什么	5
1.1 赛题不是”做一个会讲课的聊天机器人”	5
1.2 我们选择的细分领域与服务对象	6
1.3 把题目语言改写成验收合同	7
1.4 由审题形成的四个设计问题与三条排除的路线	8
第二章 从论文到设计：哪些研究真正改变了系统	9
2.1 文献不是装饰，而是设计假设的来源	9
2.2 课程不应是一篇长文，而应是可教学的活动序列	9
2.3 个性化的核心是状态更新，不是称呼变化	10
2.4 辩论能提供异议，但不能自动提供真相	10
2.5 评测单位要从回答降到断言，并把类型拆开	11
2.6 借鉴的边界与我们的增量	12
第三章 研发历程：从能生成到能交付	13
3.1 第一版的错觉：角色很多，课程却仍是一篇稿子	13
3.2 第一次转向：把个性化从文案风格改成结构约束	13
3.3 第二次转向：从”引用过资料”到”每个断言可回查”	13
3.4 第三次转向：从静态画像到领域内证据闭环	13
3.5 第四次转向：从单一管理员到机构级供给	14
3.6 第五次转向：把”生成完即可用”改成教学履约合同	14
3.7 踩坑如何变成工程约束	15
第四章 最终系统：一条受控的课程生产与学习闭环	18
4.1 总体架构与信任边界	18
4.2 七类角色如何协同	19
4.3 核心技术一：基于双端约束解耦的个性化—保真协同生成架构	20
4.4 核心技术二：基于跨厂商异构双审核与断言级定向修订的可信内容校验方法	21

4.5 核心技术三：基于可观察目标契约的教学闭环履约验证方法	23
4.6 独有面：基于受控知识库自助接入的领域可迁移生成机制	25
4.7 实操项目、机构隔离与数据边界	27
4.8 生成性能与可回滚发布	28
第五章 如何证明系统达到可用边界	30
5.1 三项核心指标：先定义，再填数	30
5.2 五层验收而不是一个总分	31
5.3 协同机制的真实性与有效性	32
5.4 难度定标的模型基础与学习效果的替代验证	33
5.5 领域泛化实证	34
5.6 双机构跨领域全链路	34
5.7 教学形态验收	35
5.8 知识接入、项目发布与恢复验收	36
5.9 证据包的完整形态与变更控制	37
5.10 当前边界与仍需验证的部分	38
第六章 逐条回应赛题与完成口径	39
6.1 逐条对照	39
6.2 四条原则与完成结论的条件	40
参考文献	40
附录 A 图表制作口径	43

事实口径说明：本文把四类事实分开写。一是赛题原文的要求；二是外部论文在其自身实验范围内报告的结论；三是本项目在冻结版本、冻结样本和固定判定协议下得到的实测结果，引用时保留原始分子、分母与样本。文中每个百分数都能追到分子、分母与样本来源，追不到的直接删掉。

摘要

XH-202630 要求系统同时接收学习者先验信息和专业知识库，组织至少三类分工明确的智能体形成分析、生成、验证、决策闭环，输出讲义、实操指南、分层测验等多种资源，并根据学习过程持续调整资源、给出知识盲点与学习路径，同时用交叉验证、内容溯源和数据保护控制大模型风险。审题时我们判断，难点不在于生成更多文字，而在于个性化与专业可信这对矛盾在单一模型内部是零和的：放开采样去迎合学情则专业内容失准，锁死在原文里复述则个性化无从谈起。

我们把全部设计押在一个判断上：这对矛盾只能用架构拆开。个性化做成输入端约束，由确定性学情诊断决定讲多深、用什么类比、出什么难度的题；保真做成输出端约束，受控检索是唯一事实入口，同一份证据同时喂生成与审核。第三条约束是：一门课不是”生成了页面”而是”履行了合同”，每个学习目标写成动作、条件、达标标准三要素，六个教学阶段逐一有场景承担，发布前由两位判官逐字引用课程原文裁决履约。

系统现由诊断、检索、生成、审核、仲裁、反馈决策、路径规划七类角色协作，学习端另设只依据当前课程内容回答的导学角色。冻结台账口径下的实测结果：幻觉率 2.08%（576 条可核验断言中 12 条无据，95% CI 1.2 - 3.6%），核心知识点覆盖率 96.0%（48/50），画像与难度适配准确率 85.2%（95% CI 77.8 - 92.6，n=108）；三个领域各两门课共 778 条断言的判错率持平在 1.2%（人工智能 1.9%、智能制造 1.5%、PLC 0.3%），全新接入的具身智能域幻觉率 1.55%（3/193）。消融中未见增益的环节、审核对数字错误的盲区、跨域样本量不足以支持优劣比较的事实，本文同样如实写出。

关键词： 垂直领域课程生成；多智能体协同；检索增强生成；教学履约验证；个性化学习；证据溯源；机构隔离

第一章 从题目要求出发:我们究竟要解决什么

1.1 赛题不是”做一个会讲课的聊天机器人”

只按”个性化知识生成”和”多智能体”这两个显眼词开发，很容易做成一个带角色头像的聊天页面：一个角色写提纲，一个扩写，另一个打分。这类演示能表现生成过程，却回答不了更硬的要求。赛题要求产出可学习、可练习、可评价的资源，还要求学习行为进入下一轮决策：输入不是一句随意的问题，输出也不是一段答案，而是一条从专业知识边界到课程资源、再从作答证据回到后续学习安排的闭环。

第二个容易误判的地方，是把智能体数量当作协同质量。真正的评分点在于四段职责是否分开，验证能否改变生成结果，决策能否改变学习者下一步看到的内容。审核角色若只显示一个分数、课程无论得分如何都能发布，它就不构成门禁；辩论若只是让两个模型连续赞同，结论也不比一次生成更可靠。我们因此把智能体理解为带输入、输出、权限和失败条件的工作岗位。

第三个难点是”垂直领域”和”个性化”的可观察性。垂直性要求关键断言能回到指定知识库，路径节点来自该领域的概念与先修关系，领域甲的表现不污染领域乙。个性化不能停在开课前选一次难度：系统必须保存”学习者在哪个领域、对哪个概念、依据哪次作答发生了怎样的变化”，并让它落到下一份资源和下一段路径上；没有同领域证据时正确的状态是标记为尚未测量。

赛题原文里有一句我们反复读的话：个性化适配与专业质量把控在单一模型架构下难以调和。这对矛盾在单模型内部确实是零和的，同一组采样参数、同一份提示词，不可能既放开又锁死。我们的全部架构设计都是这句话的展开。




图 1-1 赛题的两难与系统职责拆分

1.2 我们选择的细分领域与服务对象

主验证领域选人工智能应用开发，不是因为它容易生成，而是因为它足够难以暴露系统问题：这个领域同时包含数学与算法概念、工程工具、模型行为、评测方法和项目实践。早期跨域试验暴露过一个缺口，如果知识库只覆盖传统机器学习而没有深度学习，系统就不能仅凭名称宣称人工智能主领域已经覆盖。领域身份必须由实际概念、资源和验收结果共同决定。

迁移验收领域选智能制造，它涉及生产系统、工业数据、设备与过程，与主域差异明显，适合检查我们是否把人工智能领域的页面文案、固定路径或岗位映射偷偷写进了通用引擎。智能制造的岗位数据如果知识库和管理员都没有提供，系统应显示”机构尚未提供该类岗位信息”；但课程结构、学习路径和实操项目属于题目要求的核心资源，不能因为岗位数据缺失而一起消失。

学习者包括高校学生、转专业学习者和机构内部参训成员，共同需要是拿到与已有基础相接、内容有出处、练习可操作、下一步可解释的课程。管理端负责接入知识库、检查生成结果、发布课程、维护成员和指派范围；管理者不替引擎手工补全课程正文，课程、路径、项目和诊断都由同一引擎依据知识库与学习证据生成。

1.3 把题目语言改写成验收合同

为了避免开发后期只凭页面数量判断完成度，我们把题目要求改写成四组可验收问题。

资源生产：能否从指定知识库生成结构化讲义、可执行的实操指南和分层测验，每种资源是否真正可由学习者操作，目标是否映射到讲解、练习、反馈、迁移和评价。协同与可信：角色是否有独立职责和结构化输出，检索证据是否同时进入生成与审核，两个审核者能否独立给出结论、分歧是否交给仲裁、未通过是否阻止发布，最终可见课程是否再次接受整课审核。动态个性化：不同先验的学习者是否得到不同难度和路径，真实错题能否改变同领域概念状态并生成带证据的补救内容，两个机构的课程能否同时成立且路径、项目、报告和空态都保持领域一致。工程边界：私有资源能否按机构与账户隔离，失败时是否明确报错而不是退回通用模型编造内容，发布物能否对应到干净代码版本、服务能否回滚、测试证据能否复算。

〔表 1-1：赛题要求、系统响应、验收证据与当前状态。证据来源：赛题原文第 4 至 8 页及最终生产验收报告。状态列只允许” 满足 / 部分满足 / 未满足” 三种取值，不写” 基本完成” 〕。

这份合同也划定了本文的口径：实现了接口不等于生产环境证明了完整链路，本地测试通过不等于服务器上的真实页面通过，课程形式齐全不等于学习效果得到真实人群验证。三层分别报告，不互相顶替。

1.4 由审题形成的四个设计问题与三条排除的路线

审题结束后，研发集中到四个问题：怎样让生成内容既随学习者变化又始终受知识库约束；怎样让分歧产生可执行的审核、修订和仲裁；怎样把一次作答转成可追踪的同领域状态变化再落到路径和补救资源；怎样让多个机构同时使用时资源不互相污染。

同时排除三条路线。一是通用问答入口，它容易展示，却会削弱知识库约束，也无法稳定产出讲义、实践与测验之间的结构关系。二是为每个领域手工准备前端路径和演示数据，这样能迅速把页面做得饱满，却解释不了新增领域为何同样有效；智能制造试验正是为了识别这种假泛化，最终方案把领域注册、概念图、路径、项目候选和学情投影都放进通用服务。三是用自动测试数量代替真实效果，权限接口和结构校验适合确定性回归，课程忠实度和教学适配需要真实模型、冻结样本与人工协议，两类不能合并成一个通过率。

第二章 从论文到设计:哪些研究真正改变了系统

2.1 文献不是装饰, 而是设计假设的来源

我们在每次设计转向前先问三个问题, 而不是做完再去找文献背书: 论文解决的任务与赛题是否同构, 它的证据能支持到什么范围, 它没解决的部分要用怎样的工程约束补上。十一篇主源覆盖多智能体课堂、自动教案、目标导向辅导、知识追踪与增量认知诊断、多智能体辩论的正反两面、RAG 幻觉语料与评测框架、细粒度幻觉分类和智能体幻觉归因; 它们不共同证明本系统有效, 只提供不同层次的启发。

2.2 课程不应是一篇长文, 而应是可教学的活动序列

MAIC 展示了大模型智能体可以围绕课程组织教师、助教和同伴等角色, 并报告了 500 余名学生、10 万余条学习记录的初步使用数据[1]。我们借鉴的不是角色名称, 而是”课程是一组连续教学活动”的认识。边界要说明: 该论文验证的是教师上传课件、智能体生成资源、教师再复核的半自动形态, 支持不了”任意知识库一键生成可靠课程且无需复核”, 也替我们证明不了知识库接入能力。

LessonPlanLM 把教案拆成结构化教学组件并把检索参考引入生成, 其训练数据包含 139512 份教案与 521326 个结构化组件, 在论文选定的 50 组比较中约八成生成教案被专家评为与人工教案相当[2]。这促使我们不再只校验”有没有若干场景”, 而是建立教学履约合同。论文的专家比较限于其数据与样本量, 不能外推为本项目课程已达教师水平, 所以终审必须检查最终可见内容本身。

GenMentor 把目标分解、技能识别、差距分析和路径规划串成多智能体流程[3], 它让我们意识到路径要同时读取目标、先修关系和学习者证据, 而不是从课程目录顺手复制。项目由此形成”领域概念图加同领域掌握证据”的规划方式: 无证据的节点显示未测量, 未经人工复核的图边只作为软建议。论文没有给出我们采用的阈值、更新规则和领域桶设计, 这些由自己的校准实验负责。

2.3 个性化的核心是状态更新, 不是称呼变化

知识追踪把学习过程看成随作答更新的隐变量而不是固定标签[4]; 增量认知诊断进一步指出真实在线教育会持续出现新学习者、新题目和新交互, 状态必须在线更新[5]。这两类工作给了我们一个约束: 系统可以展示对掌握程度的估计, 但必须保留它依据的概念、领域和作答历史。论文没有给出本项目的更新公式和阈值, 这些参数由我们的实现、校准集和测试说明承担证据责任。

在产品实现中, 学情是按领域分桶的状态而不是生成后不变的报告: 一次人工智能课程的错题只能更新人工智能桶中的概念, 管理者预览课程不写入学情; 当前领域没有作答证据时界面直接说明尚未形成该领域测量。

2.4 辩论能提供异议, 但不能自动提供真相

多智能体辩论研究表明, 在若干事实性和推理任务中让多个模型交换判断有机会改善结果[6]; 另一项系统研究指出, 这类协议并不稳定优于自一致性或集成基线, 结果对协议、角色和超参数敏感[7]。两篇合在一起比单独引用”辩论有效”更有用: 不能把回合数、角色数量或一致投票当作正确性的替代品。需要说明的是, 第二篇的结论是”不稳定且依赖设置”, 不是”更多轮次必然无效”, 也没有证明模型异构是唯一可靠路径; 我们采用有限轮次、跨厂商异构与冲突仲裁属于工程选择, 其收益由第五章的内部消融和失败样例承担。

因此系统中的两个审核者使用不同厂商的服务, 读取同一份证据和课程断言、输出结构化判词, 运行时互不可见。意见一致只是进入下一道门禁的条件, 不等于事实已被证明; 证据不足时允许的结论是”超出资料范围”, 不由多数票补全。修订只在受控轮次内进行, 超过边界就停止并显式失败。

2.5 评测单位要从回答降到断言，并把类型拆开

RAGTruth 构建了近 18000 条自然生成的检索增强回答并做人工细粒度标注[8]。它启发我们把审核对象从整段流畅度下沉到可核查断言：一个段落可能大部分正确，只在关键条件、数字或因果关系上越界，整段打分容易让错误被平均掉。系统因而要求关键内容携带来源标识，审核结果绑定具体断言和证据片段，修订只针对被指出的部分。我们在该语料上按既定规则抽取 900 条做外部测试，确定性检测层的 F1 为 0.336；这是本项目的测试结果而非论文结论，它说明当前检测器仍需校准，我们不把它写成“外部金标准验证通过”。

ARES 把检索增强的评测分为上下文相关性、回答忠实度和回答相关性，并强调自动评审需要人类标注校准[9]。我们据此把“找到了资料”“内容忠于资料”“内容回答了教学目标”分开检查：检索命中不等于断言受支持，忠于知识库也不等于适合当前学习者。FAVA 提出细粒度幻觉分类与片段级编辑修正[10]，我们借用它的分类学口径：幻觉率不能只报一个总数，还要按类型拆成构成表，且构成表加总必须等于总数。AgentHallu 定义了幻觉归因任务，报告最强模型的步骤定位准确率只有 41.1%[11]，这条证据影响了取舍：与其事后追责哪一步产生了幻觉，不如在生成侧用证据边界预防。




图 2-1 十一篇主源对六项设计决定的影响关系

2.6 借鉴的边界与我们的增量

这些研究提供了课程活动化、目标分解、动态状态、多方审核和细粒度评测的基础，但没有一篇同时处理赛题要求的全部链路。我们要补的是把它们放进一个可部署、可分租户、可追责的生产系统：接入要形成可检查产物，合同要约束最终课程，审核要能阻止发布，作答要触发同领域补救，发布版本要能回滚。我们的增量是把这些研究之间缺失的接口做成可运行的闭环，并把失败状态也做成产品行为。

第三章 研发历程:从能生成到能交付

3.1 第一版的错觉:角色很多,课程却仍是一篇稿子

项目早期沿用多角色课程生成的直观方案,界面上能看到多个智能体接力。它解决了“一个模型从头说到尾”的单调感,却没有解决教学质量:目标写成“了解”“熟悉”这类不可观察的词,场景之间只是换角色复述,测验与前文没有映射。课程看起来完整,学习者却不知道完成什么动作才算学会。

3.2 第一次转向:把个性化从文案风格改成结构约束

第二版把画像做成可机械复查的学情蓝图:学情诊断读取一句学习目标和五个维度的行为自评,输出难度档位、讲解深度、组件与图示配额、类比领域、篇幅档、测验难度带,每项附推导依据,同一个人两次诊断得到同一份蓝图。这一版确立的纪律是个性化改的是结构、不是语气:零基础版的例子取自排队、做菜,工程师版直接谈接口契约与缓存失效,学情报告里每处差异都指回画像里的那个字段。

3.3 第二次转向:从“引用过资料”到“每个断言可回查”

早期检索增强版本会在课程末尾列参考资料,但正文中的具体说法与资料之间没有稳定关系,模型仍可能把常识、训练记忆和知识库内容混在一起;学习者看到“有参考文献”容易过度信任,管理员也无法快速判断哪句话越过了知识边界。我们随后把来源标识贯穿检索、生成和审核:检索器返回 `source_id`、所属语料和位置,教材原文以摘录块直贴进讲义、不经模型转写并带出处角标,审核者逐项比较断言与证据给出三值结论。定向修订必须同时读取原断言、审核理由和允许使用的证据,不能重新自由生成整页。

3.4 第三次转向:从静态画像到领域内证据闭环

第二阶段能按开课问卷选择难度,但管理端切换课程后,学习端的变化主要停留在课程列表,路径和学情仍可能沿用旧领域。修订后,当前领域由机构课程指派、个人语料选

择和个人领域设置按明确优先级决定；掌握度、置信度、回忆状态、难度和能力分值按领域桶存储，页面只投影当前桶；路径节点来自该领域接入阶段形成的概念与先修图。错题补救不再生成一段通用安慰：反馈角色读取实际错题、历史作答、当前领域状态和同一知识库证据形成补救提纲，再进入原有的生成与审核链。掌握判定设双阈值，估计值与置信度同时达标才算掌握；复习排期由引擎侧的开源 FSRS 排程接口给出，状态不落盘、由证据流重放计算，同一作答序列必然得到同一排期。

3.5 第四次转向：从单一管理员到机构级供给

加入第二个管理者后，资源互相污染立刻成为核心风险。我们没有更换整个账户体系，而是在现有会话和学习者键之上增加机构、成员、邀请码、语料归属和课程指派；最重要的决定是把知识库归属收敛为单一事实源，旧映射与新标记冲突时按失败关闭处理，不猜测归属。

3.6 第五次转向：把“生成完即可用”改成教学履约合同

单场景审核通过后，组合成整门课程仍可能产生新问题：场景顺序改变时前置概念可能出现在应用之后，页面只展示生成对象的一部分时审核过的内容未必等于学习者看到的内容，目标覆盖了讲解但没有练习时单个段落都正确也不能说明课程可教。这一轮我们把教学结构做成了机械可检查的合同：每个学习目标由动作、条件、达标标准三要素构成，课程必须覆盖六个教学阶段并在同一目标下严格顺序成立，不合格的大纲带着逐条违规理由回修，三轮仍不合格就拒绝生成。规则和校验位见 4.5 节，这里只记三处被实测逼出来的调整。

一是修订轮次从两轮提到三轮。模型在严格合同上单条规则的掉落带随机性，2026 年 9 月 2 日智能制造域实测中迁移屏漏挂两个目标标识，两轮都没补上。二是策略证据的确定性降级。教学策略支持标准、逆向设计、费曼解释三种，后两种要求额外的策略证据字段，实测中模型常常选了逆向设计却排不出表现性证据、反思修订、迁移的严格顺序，

两轮修订仍栽在同一条上，整门课因此被拒；策略证据是规划元数据、不是学生可见内容，也不属于六阶段门禁，所以当且仅当剩余违规全部来自策略证据时，系统降级为标准策略并重新校验，六阶段规则一条不减，降级如实写进日志。三是练习落点的收紧。原口径允许练习屏指向互动场景，但清点后发现八个交互控件模板全是探索型控件、没有答案判定；机械检查曾放行这类被动模板，而两位语义判官一致判它是” 点击看演示”。现在练习与反馈重试必须落到能收作答并给反馈的场景，机械口径与语义判官口径就此统一。




图 3-1 五次研发转向与它们改变的模块

3.7 踩坑如何变成工程约束

研发中最有用的记录是那些” 本地看起来通过、上线会出错” 的细节。这一节按现象、根因、修复、纪律记录本轮的几个。

难度分层在新建库上悄悄失效。 域接入流水线给每个证据块写的难度值取了管理员声明区间的下界，填” 分三档” 建出来的库，索引里的难度是个常数：智能制造 1703 块、

时序数据库 2716 块无一例外落在最低档。个性化的证据闸恰恰靠这一格生效，难度恒定等于这道闸不存在。修复不复杂，改走与主库相同的机械特征分位法并原地回填；有价值的是验证方式： $n=18$ 的置信区间宽到从准确率上判不出修复效果，所以改走机制级验证，看同一查询在不同难度上限下返回的证据块修复前后是否不同。纪律：凡”代码写好了”的声明，一律以线上行为为准。

提示词把模型逼到编造。 早期提示词同时要求解释机制和禁止复述教材，在语料覆盖薄的领域这两条会合谋把模型逼到编造，跨域验证显示九成以上错误断言来自这类自主发挥。改版后的分档取材规则把”不知道”合法化：摘录给了因果关系就推导因果链，给了真实数值就附手工计算小样例，只给结论就只讲结论和适用条件，没覆盖的机制只写导读并显式标注。

同厂商审核会偏心。 消融中发现可复现的模型家族偏置：同一厂商生成的修订内容，该厂商的审核模型会给出更高评分。两次重复判定不等于两次独立判定，共享偏置让双审核退化成单审核，这是审核必须跨厂商的实证来源。配套做了证据依赖检验，把断言与证据的对应关系故意打乱后判定大面积翻转，说明判定真的依赖证据内容。

引擎检索的瞬态空窗把整单枪毙。 2026 年 9 月 2 日实测中，同一条需求首查 0 命中、几分钟后原样重查 6 命中；另一次是向量检索间歇失败后静默降级到词法通道，长中文查询过不了词法充分性门、引擎如实回空。证据闸原来单次 0 命中就停整门课，修复是空结果隔 3 秒复查一次、仍空才判未命中，判据不放宽。降级发生在引擎内部，产品层看到的是一个合法的空结果。

判官在整课文本上超时是常态。 审核调用原设 180 秒硬超时，而课程级终审吃的是整门课文本，实测两门课并发时一轮两位判官双双超时，结果是零条断言加 flagged、整课定草稿。修复分两步：调用超时放到 300 秒，代价只是真失败时晚两分钟报出来；课程级审核整轮失败时再跑一轮，第二轮仍失败照旧失败关闭，不伪造判词。

控件文案被抽成教学断言。 智能制造域实测中，“操作流程 进度 0% 重置练习 参考资料: S7-1200……”被判官拼成一条断言并判为含无关系统提示文本，而修订环改不了控件文字，整屏永远 flagged。修复是在抽取可审核文本时剔除按钮、进度条、输入框、下拉框的字面。

这些问题沉淀成的纪律见 6.2 节，另有一条属于测试本身：所有隔离测试都要求负向与正向成对出现，否则区分不出权限正确和系统整体不可用。

第四章 最终系统:一条受控的课程生产与学习闭环

4.1 总体架构与信任边界

系统分为产品层、引擎层、存储层和受控外部服务。产品层基于 Next.js 实现，包含管理端、学习端和公开说明页，承载交互、课程持久化和生成流程编排；引擎层基于 Python 与 FastAPI 实现，用有向状态图组织检索、诊断、接入流水线和掌握度回写这些有状态计算。产品层通过内部令牌调用引擎，引擎只监听内网回环地址。选状态图的依据是，多智能体协同的本质是带条件转移规则的有限状态机：审核不通过要返回重生成，分歧要升级仲裁，预算超限要熔断；规则显式定义后执行过程天然可视，协同调度可视化由此直接获得数据支撑。

存储层分别保存账户与会话、机构成员关系、语料及其归属、课程快照、领域注册、学习者分领域状态、审核证据和项目发布版本。外部模型服务和 GitHub 处于不可信边界之外，可以提供候选内容或判断，但不能绕过本地结构校验、权限检查和发布门禁。面向用户只有真实模型推理一条路，调用失败就明确报错；工程内部另有一条确定性引擎专供回归测试，两类统计从不混合上报。




图 4-1 产品层、引擎层、存储与外部服务的信任边界

4.2 七类角色如何协同

七个智能体按分析、生成、校验、决策四段排布。这不是流水线：流水线上每一环都信任上一环，我们的审核环节以不信任生成环节为前提，两个审核者之间也互不可见。

分析段有两个角色。学情诊断读画像输出学情蓝图，用确定性规则实现，推导链可机械复查。知识检索是全局唯一的事实入口，双通路应对两类互补故障：语义向量通路扛得住改写后的表述但可能漂移，词法通路精确命中术语但对表述变体脆弱；自有标注语料集上 top-6 召回准确率为 93% 至 100%，这也是我们否掉外挂通用检索框架的量化依据。检索结果同时喂给生成和审核，评价内容的标尺和生成内容的边界必须是同一份材料。

生成段只有内容生成一个角色，它是唯一以模型采样为核心的环节，也因此被其余六个盯得最紧：在学情蓝图、事实边界、分档取材规则三重约束下产出四类资源，故障按屏止损。校验段是两个分属不同厂商的审核者加一个仲裁者，仲裁只在分歧时激活，三个出

口是放行、标记风险后放行、拦截转人工。决策段包含反馈决策和路径规划：前者把作答经指数滑动平均回写进概念掌握度，是确定性实现，任意时刻的状态都能由证据链重放推导；后者结合概念图与同领域状态安排下一步。导学角色不算第八个决策角色，它只依据当前课程和允许的证据回答追问并判分，不能修改课程事实。




图 4-2 七类智能体的协同状态图

4.3 核心技术一：基于双端约束解耦的个性化—保真协同生成架构

这套架构把 1.1 节的零和矛盾拆成两条互不侵犯的约束链。输入端，学情蓝图经描述通道注入生成器而不改生成器接口，保住它的独立可测试性；掌握度达到阈值的教材块直接跳过，跳过原因随检索结果回传。为保证整门课一致性另有两条约束：已讲概念登记避免重复定义，全课统一类比从第一屏正文提取喻体后续沿用，提取失败就空缺不强造。

输出端，受控检索是唯一事实入口，同一份证据同时喂生成与审核。这一端的贡献量有对照数据：不接知识库直接生成，内容与教材证据的对应度为 0，写得流畅但没有一句

能对到教材上；接入受控检索后，同一套 60 组确定性校准集上的忠实度为 0.928（claim 级三态判定，属校准一致率口径，不是最终成绩；此值曾随代码演进写过 0.851 与 0.913，均已作废，以指标台账为准）。这一跳是全系统最大的单项增益。

调节分两个时间尺度：课时内答错即回写，掌握度由证据账本折叠（估计值与置信度成对）更新，难度档回调、补练插入、路径游标回拨当场发生；跨课时的复习时机由引擎侧的 FSRS 排程接口给出，课堂端不自己维护遗忘模型。证据边界如实划定，只有测验交卷与导学判分两类进证据池，互动教具只有停留时长、判不出对错。




图 4-3 双端约束解耦与两个调节时间尺度

4.4 核心技术二：基于跨厂商异构双审核与断言级定向修订的可信内容校验方法

内容从教材到学习者眼前要过四道闸，闸位依次后移、拦截成本依次升高，原则是让问题在成本最低的闸被截获。入库闸零模型成本，做可检索性、概念词表、结构画像和语

料适配性预警，占位空壳与结构残缺的语料在入口被拦下。生成闸靠机制防错，检索出的原文直贴不转写。审核闸靠模型对抗，断言级三值判定加跨厂商双审与仲裁，判不下来的断言标注超出资料范围、原样挂在页面上并带风险标识。交付闸做机械验算，代码块进沙盒运行、数值等式程序化复核，拦截前三道共同遗漏的”形式合规但算错了”的内容。判定落盘时绑定到具体教材块，decidedBy 标识判定出自双审共识还是仲裁，sourceIds 让界面点击即可跳转原文。

修订环这一轮做成了两级，都有界。屏级修订环最多两次修订、三轮审核。原来只许一轮修订，而复审那一轮里新冒头的判错断言（第一轮判官没抽到，或仲裁到第二轮才裁定）拿到了修正案却再没有消费机会，整页定格 flagged、发布门永远拒，双域真实生成各挂两屏都是这个形态。修订产物有结构守卫：必须保留原内容的关键结构且元素不能变少。守卫本身也是一个坑：原来的写法比较两边的 type 字段，而讲义、测验、互动三类内容的顶层没有这个字段，两边都是 undefined、条件恒真，等于没有守卫。

课程级定向修订环是这一轮新加的。全课事实终审原来只裁决跨页冲突、不提供修订入口，于是一条术语抖动就把整门课永久钉在草稿：教学合同写”感知、决策、执行”，教材写”感知、思考、行动”，全课终审把每一处沿用合同术语的句子判错，仲裁给了修正案却没人消费。现在的做法是把判错且带修正案的断言按文本相似度定位到具体屏，只改那几句，重审那一屏，再跑一次全课终审；修坏了保留原稿，第二次终审仍判错就按草稿落盘，不放宽门禁。

仲裁的第三个出口”拦截转人工”这一轮也做实了。此前它只是审核记录里的一个标签，草稿没有出路；现在机构所有者可以在管理端单课页看到门禁当时被拦的每条原因与全部判词，复核后显式放行，系统记录操作者、时间与当时的拦截原因，随课程一起落盘；放行只改可见性，不改任何审核记录，撤回即回到门禁判定。学习者侧按指派可见，跨机构访问照旧返回 404。发布门因此有三条明确的出路：机器放行、旧协议放行、人复核放行，三条在课程文件里都能区分。




图 4-4 断言级证据链与两级有界修订环

4.5 核心技术三：基于可观察目标契约的教学闭环履约验证方法

教学履约合同位于领域知识和课程场景之间。每个目标由动作、条件、达标标准组成：不写”理解检索增强生成”，而要求学习者在给定语料和查询时指出检索、生成与引用的对应关系，并依据检查表发现一处无证据断言；这样的目标能被练习与评价，也能让审核者去找具体证据。合同的机械校验分三处。大纲阶段校验目标三要素、六阶段引用、同目标下练习早于反馈早于评价的严格顺序、评价映射覆盖每个目标，以及练习与反馈必须落在能收作答的场景，不合格进入最多三轮定向修订。场景生成阶段，每个场景声明它服务哪些目标和承担哪些教学阶段，模型给的值会被校验后的合同覆盖。发布前做履约终审，读取最终可见内容的精确文本，逐个核对”目标乘教学阶段”的项，要求每条通过判定的证据引用能在对应那一屏中定位。

终审的两处细节是被实测逼出来的。其一是判词的引用绑定口径。原来要求引用整段连续逐字命中该屏文本，实测两位判官四次判词全因此被拒：屏内容是结构化字段，判官天然会把题干和解析拼成一句、或用省略号跨过选项，每一段都真实出自该屏，只是拼接。现在改成分段逐字匹配，按省略号、句末标点和换行切段，每段去标点后不短于六字的都必须是该屏可见文本的连续逐字子串，换屏和改写的引用照拒。其二是判官的媒介口径：这门课的媒介是幻灯片、测验、互动控件和项目式任务，没有线下实操台，所以”学习者实际执行”以媒介可承载为准，在测验或控件中亲自完成识别、排序、判定、说明、补全关键步骤即算执行；但目标动作若在这些媒介里根本无法执行或无法判定，仍判不达标并写明是目标不可评。

判词结构本身也是可校验对象：任一判官返回缺项、截断或结构无效，系统带着具体拒绝原因回喂重试一次，两次仍无效就失败关闭，不伪造判词。机械验算保持三态，确定通过、确定失败、无法执行，只有确定失败才阻断，无法执行如实标记为警告，因为把”没查成”写成”查过没问题”和把”查出问题”写成”通过”同样有害。




图 4-5 教学履约合同的六阶段与三处校验位

大纲阶段另有两处前移的检查。一是逐屏证据覆盖预检：结构校验通过后，对每一屏用与屏级检索完全相同的查询和难度上限探一次库，零命中的屏作为违规进入同一套修订循环。它解决的是一个具体故障：需求点名”安全前置”而库里只有 ROS2 和 PLC 文档，这样的屏以前要到生成进度 40% 时才被屏级证据闸击杀、整单作废；探针自身异常按覆盖处理，不拦车。二是术语基准注入：把需求命中的前六块摘录作为基准喂给大纲生成，要求学习目标、达标标准和场景文案中的术语与摘录一致，把 4.4 节那个术语抖动问题从终审前移到大纲。

4.6 独有面：基于受控知识库自助接入的领域可迁移生成机制

垂直领域不是上传一个文件名后立即成立。接入服务把过程拆成八个阶段、九个任务位（向量索引是阶段三的异步旁路）：接收与清洗、切块入库、检索索引与向量旁路、知识整理、金标派生并冻结、试跑课程、指标复测、个性化注册。阶段之间有显式依赖，后

续阶段不能把前序失败视为完成；亮灯条件不是模型说已完成，而是该阶段的结构化产物经过校验并被服务登记。

试跑体检不走形式：在新库上真实生成两个档位的内容，复测断言级幻觉、对冻结金标逐点标记讲到与未讲到、盲审两档是否有实质差异，未检测与检测未通过是两个独立状态。试跑与指标复测可选，个性化注册必需。流水线最后把新库登记进域注册清单，学习端的域选择器、输入框示例和安全横幅运行时直接读它，新库上线不改一行前端代码。

知识图谱和先修边由接入过程生成，这里有一条如实的边界：自动推断的先修关系交第三方模型盲态逐条判方向，判对率只有 47%、接近随机，所以先修边一律标为软约束，只用于路径推荐排序。概念词表的产出量也误判过一次：最初采样 120 个小节只抽出 1 个合格概念，判定标准不变、扩大到 500 个小节后抽出 66 个概念和 51 组先修关系，产出不足是输入量不够，不是标准过严。




图 4-6 八阶段知识库接入流水线与产物依赖

4.7 实操项目、机构隔离与数据边界

实操项目最容易出现“看起来能做、点开却不存在”的问题。系统先通过 GitHub 接口获取真实候选仓库及星标数、许可证、更新时间和说明文件，模型只能在候选中选择并生成三到六个步骤，编不出清单外的条目。生成结果先进入管理端草稿，管理员核对许可证、维护状态、运行环境和教学匹配后发布带内容哈希的不可变快照；恢复旧版本是以旧内容创建新版本，不覆盖当前记录。智能制造没有岗位数据时项目仍依据课程目标生成，岗位字段留空并说明来源缺失。

机构模型包含机构、成员、邀请码、知识库归属和课程指派。邀请码可轮换，加入操作大小写不敏感且幂等；成员移出和密码重置只允许所有者执行，重置密码同时删除该账户的全部会话。没有机构标记的语料为公共库，有标记的仅同机构可见；域清单、技能图谱、域学习路径三个取数口走同一道可见性闸。课程指派面向具体成员，指派前服务端检查课程真实存在、对该机构可见、已面向学习者发布并具有已登记领域；管理员预览是只读行为，不改变任何学习者状态。

数据上，系统只收集必需信息，不要求邮箱、电话和真实姓名；密码用带盐的 `bcrypt` 派生值保存，会话走 `httpOnly` Cookie；用户可导出自己的数据，也可在验证当前密码后删除账户，敏感操作受频率限制并按失败关闭处理。机构管理员管理成员身份与课程供给，不因此获得读取成员全部私人学习内容的权限。模型调用只发送当前任务所需的课程片段、结构化状态和审核对象，知识库归属检查发生在检索之前，日志不记录明文密码、会话令牌或无关个人信息。




图 4-7 双机构权限与领域数据流矩阵

4.8 生成性能与可回滚发布

这一轮我们第一次完整拆解了整课生成的墙钟时间。9 屏课程实测 57 分钟：大纲 5 分钟、屏级生成与审核 37 分钟（并发 2）、课程级尾巴 15 分钟。三处针对性改动是：课程级两段终审并行执行；复审改为只审改动段的增量模式，因为修订只改判错的那几句、一页里绝大部分文本与上一轮逐字相同，重判是纯浪费（实测一轮收的屏审核中位数 119 秒，走到第二轮是 375 秒）；并发度从 2 提到 3。三项改动落地后，2026 年 9 月 2 日 17:31（UTC）在线上服务器同时发起两门课：人工智能域 8 屏 37 分钟、智能制造域 11 屏 42 分钟（两门并发，共用一套模型配额），两门都走完全部屏级审核与课程级终审后以草稿落库。相比单课 57 分钟，并发两课的单课墙钟缩短约三分之一；稳定网络下单独跑一门的数字仍未量。

生产发布从干净且已提交的代码版本构建，打包前扫描敏感信息和无关文件，产物附带 SHA256 清单；服务器解包后检查路径、符号链接和权限，应用由非特权服务账户运行。新版本先放入独立发布目录，完成依赖链接和健康探测后再切换当前版本指针，首页、认证、管理页和真实课堂页都在探测范围内；关键探测失败就切回上一个不可变版本，而不是在半完成目录上继续修补。

这里要写下一条纪律：发布门拒绝是有效结果。终审判不过的课程保留为草稿、进入管理者复核队列、学习者不可见，这本身就是系统按设计工作。我们不会为了让一门课通过而放宽门禁判据；本轮所有修复动作，改的都是”该拒的没给修订机会”“该过的被格式误伤”，没有一处降低了判据本身。

第五章 如何证明系统达到可用边界

5.1 三项核心指标:先定义, 再填数

赛题给出幻觉率、画像与难度适配准确率、核心知识点覆盖率三个指标。我们不先生成百分比再解释，而是先冻结定义、样本与判定协议。下表实测结果来自冻结台账口径，本轮在最终发布版本上的重跑结果另行标注。

指标	赛题要求	冻结台账实测	分子/分母	评测设计	本轮同版本重跑
内容幻觉率	<5%	2.08%	12 / 576 条 可核验断言	57 次真实模型运行；断言级三判官多数表决	满足。冻结版本 run 20260804, metrics.json 键 api_hallucination_v2, 复算命令随键给出
核心知识点覆盖率	≥90%	96.0%	48 / 50	6 门金标课程；金标由教材目录独立构建、生成前冻结	满足。metrics.json 键 kc_coverage_v1, 金标文件随 6 门课程一起冻结
画像—难度适配准确率	≥85%	85.2% (95% CI 77.8 – 92.6, 下界未过线)	92 / 108	12 主题 × 9 画像；三名独立判官按预注册细则盲评	部分满足。点估计过线、95% 置信区间下界 77.8%

指标	赛题要求	冻结台账实测	分子/分母	评测设计	本轮同版本重跑
					未过线； metrics.json 键 adaptation_a ccuracy_2a, run 20260813- 0013

评测纪律写在这里供复核。幻觉率的单位是可核查断言，分母为需要知识支持的断言总数，分子为与知识库冲突或无法由允许证据支持却被表达为事实的断言数，纯教学组织语句不进分母。金标先冻结再生成，防止对着答案出题；判官盲评，只见资源正文不见画像，判官阵容与生成侧模型全部异族。置信区间用按主题重抽的聚类自助法，因为同主题资源共享素材、独立性假设不成立。评分细则版本化管控，判据不变才允许跨轮比较。

幻觉率的分类构成表按 FAVA 的口径设计[10]：无据断言按类型拆分，构成表加总必须等于总数。这一轮 12 条无据断言只做了三态判定（supported / weak / unsupported），没有按类型标注，构成表因此没有产出，这是本轮评测的一处缺口，下一轮标注时补。端到端用例与确定性回归分账如下：真实模型端到端评测 57 个 run、576 条可核断言（幻觉率）、108 组画像与资源对（适配准确率）、6 门金标课程（覆盖率）；确定性回归为引擎侧 697 条与产品层 4818 条单元用例，两类数字分开报，不相加。

5.2 五层验收而不是一个总分

第一层是结构与单元测试，检查教学履约合同、课程终审、机构权限、领域解析、知识接入、项目版本和隐私接口的确定性规则，产品层 4807 个用例、引擎层 697 个，每

次交付前全量回归。缺陷修复有一条硬纪律：每修一个缺陷新增一条用例，先把代码退回修复前确认它不通过，再恢复修复确认通过。第二层是服务集成，检查课堂端与引擎、存储、模型桥接和外部候选源之间的真实请求。第三层是生成质量评测，用冻结知识库、画像和课程目标运行真实模型，端到端 60 组用例，满足不少于 50 组的要求。第四层是角色化浏览器验收，走完接入、发布、指派、学习、错题、补救和报告；第五层是生产发布与回滚，确认当前运行版本与被测版本一致。

每一层的失败都必须保留真实路径：模型超时不能被固定演示结果替代，知识库不足不能退回通用常识，岗位数据缺失不能生成虚构岗位。本次发布版本上的结果：产品层 4807 个用例通过、10 个跳过；引擎层 697 个通过；TypeScript 全量类型检查通过；改动文件 ESLint 零错误；仓库卫生扫描（密钥与协作痕迹）零命中。

5.3 协同机制的真实性与有效性

评分标准把”退化为单模型直接生成”列为最低档，所以这一节用实验数据回答两个问题：协同是真的吗，协同有用吗。

真实性方面，576 条断言中标出 12 条无据与若干超纲，仲裁拦截和定向修订都实际执行过并全程留痕，每一步用了哪个引擎在轨迹里如实标注。有效性方面，修订环节的增益来自修订器强度：强模型修正弱模型内容提升 0.103 ($p=0.0012$)，反向配置无显著增益，据此把最强档位配给修订节点。

消融实验如实报告无差异。四个递进档位（裸模型、加提示词模板池、加审核门、加全课连贯约束）共生成 13 门课对照，判定标准实验前注册锁定。结果没有出现每加一层涨一截：加审核门前后的有据率是 88.7% 对 88.8%，统计上无差异。原因与四道闸的设计自洽，知识库约束在源头压住了绝大部分编造，留给审核门可拦的问题本来就少。针对”审核门是否形同虚设”，运行日志给出否定回答：四档的实际送审次数 0/0/5/5 与配置完全对应，配了审核就真实执行，只是拦截量小。我们如实呈现，不包装成增益。

审核的能力盲区做了测定。往正确课程里故意植错，同一屏正文只改一句里的一个数，原版与改错版各判一次，扰动版被判错或存疑而原版没被误标才算一次成功检出：87 对有效配对的宽口径检出率 35.6%；其中换物理单位这一类能识别 58.6%（29 对），因为换单位往往把句子也说反了；直接把数值翻倍只识别出 10.3%（29 对，自助 95% 区间 0.0 - 24.1%）。大模型审核看得出话不对、看不出数不对，这是结构性弱点。补救不是让识别变准，而是把带数字的句子按阈值、单位、参数与后果拆成独立断言送审，并把模型没把握的数字显式标出交人工复核。遗漏从”看不见”变成”有人看”。

〔表 5-1：消融档位、植错检出、修订器强度三组实验的结果与”不支持的结论”列。证据来源：冻结实验记录与本轮复算脚本。〕

5.4 难度定标的模型基础与学习效果的替代验证

参数恢复实验：预设一批已知能力值的虚拟学习者，由掌握度模型生成作答记录再反推能力，主成分相关系数在 0.767 到 0.779 之间（阈值 0.5 口径）；与 DINA 认知诊断模型在同一批合成数据上对账，全部 100 个学生×概念格的一致率 80.0%，剔除 17 个存疑格后 91.6%，两数并列不择优。评分细则条目打乱后重判三轮，与原判一致率 86.4%（Cohen’ s κ = 0.845），说明评分取决于内容本身。

学习效果目前只做到模型模拟这一层，如实标注为替代方案。由一个模型扮演零基础学习者闭卷阅读生成课程并作答 17 题的三层题库（复述、迁移、诊断），另一个模型盲态判分，以直接研读原版教材为 100% 基准。实验组在”应用所学完成任务”类考题达成率 87%、“换新场景运用”类 86%，与教材基准的差值置信区间跨零，在该评测分辨率下与教材分不开；空材料与安慰剂对照臂分别只得到基准的 10% 与 21%，排除模型靠自身知识答题的干扰。局限写清楚：模拟学习者不能替代真人实验。

5.5 领域泛化实证

两个跨大类知识库在提交前通过管理端界面完整走完接入流水线：智能制造域（《动手学 ROS2》与《S7-1200 PLC 编程及应用》合并，1703 块、259 幅原书插图）与工业时序数据库域（Apache IoTDB 官方文档，2716 块，Apache-2.0 许可）。重建后同一批 6 门课 778 条断言的判错率：人工智能 1.9%（4/207）、智能制造 1.5%（4/261）、PLC 0.3%（1/310），三域持平；另一个全新接入的具身智能域幻觉率 1.55%（3/193），都低于赛题 5% 的合格线。

跨域隔离验证：同一需求在三个库里不调参数各生成一门课，正文证据词命中本域 12 至 107 次、命中异域仅 1 至 2 次，逐条核验后异域命中全是用语风格误报。反向对照：一条不属于任何领域的中性需求在三个库检索全部为空，拦截机制阻止了零证据课程的生成。跨域画像适配用测前冻结的用例集各测一轮，智能制造 77.8%、时序数据库 94.4%；必须如实说明， $n=18$ 的置信区间宽（智能制造 CI 54.8 - 91.0），这个样本量只支持等价检验，不支持与主域做优劣比较，我们按此口径引用，不超采。

5.6 双机构跨领域全链路

生产验收采用 A、B、C、D 四个符号身份，不在文档中暴露演示账户：A、B 属机构甲，C、D 属机构乙。A 接入人工智能知识库、生成并发布课程后只指派给 B，C 对智能制造执行同样流程并指派给 D；两个管理者先后登录时，成员列表、私有知识库、课程候选和发布记录必须保持独立。

B 登录后首页应出现人工智能领域的已指派课程，课程内容具有教学履约合同、来源标识和审核结果，学习路径读取人工智能概念图；B 完成一次真实错误作答后，系统要更新对应概念证据、生成同语料补救内容并改变下一份资源。D 登录后得到智能制造课程、路径和项目，不继承 B 的掌握度或页面文案；机构乙没有岗位数据时岗位区显示明确空

态，这不是课程失败。随后做双向越权检查，每个负向请求旁边必须有同资源的授权身份正向结果，以证明拒绝来自权限规则而不是资源不存在。

2026 年 9 月 2 日 17:31 (UTC) 在线上服务器由 A 与 C 同时发起真实生成：人工智能域课程 J3Zc41em66「AI 智能体零基础入门」8 屏、37 分钟走完全链路；智能制造域课程 dQTm8hcsPC「装配工位联调入门」11 屏、42 分钟。两门都以草稿落库，拒因相同：全课事实终审未过、履约合同未满足，双判官（Qwen3.6-35B-A3B 与 DeepSeek-V3.2）判词一致。两门课在管理端单课页可由机构 owner 走人工复核放行，定稿时尚未放行，因此 B 与 D 的正向访问、双向 404、岗位空态这三项没有在线上留下本轮记录；本地同一代码版本上的验证结果是：甲机构 owner 放行并指派后学员 B 访问返回 200，乙机构学员 D 访问同一课程返回 404。智能制造域岗位页在两处环境都显示固定原句「本机构管理者在接入该领域时未提供岗位/技能清单」，没有借用人工智能岗位补位。

5.7 教学形态验收

课程质量不能由页面漂亮程度替代。两域各选一门最终生产课程，对每个可观察目标检查六类证据：是否激活必要先修，是否给出与知识库一致的示范，是否要求学习者实际操作，是否依据操作提供反馈和重试，是否安排不同情境的迁移，是否有能判断达标标准的评价。实操指南另验证环境、输入、步骤、预期产物和失败诊断；分层测验检查题目与目标映射、难度依据、答案与证据、错题后的真实补救；导学角色遇到超出知识库边界的问题应承认当前课程未覆盖。

除逐项结果外，这一轮还报告两个过程指标：教学履约终审的判词结构一次通过率，以及发布门拒绝的原因分布。后者是衡量门禁是否真在工作的直接证据，拒绝率为零反而说明门禁可能形同虚设。截至本文定稿，两门课都没有以”机器放行”状态通过发布门：人工智能域最后一跑履约合同六阶段全部通过双判官终审、被全课事实终审的一处跨屏不一致拦下；智能制造域最后一跑（17:01）在大纲阶段被拒，前一跑（16:28）通过大纲与全部屏级审核、履约终审在前置激活与迁移两个阶段被判不满足。两门课的逐项判词与拒

绝原因保留在课程草稿文件中，可在管理端单课页查看。2026 年 9 月 2 日 06:56 - 17:01 (UTC) 在本地同一代码演进线上对两门课共重跑 26 次，门禁把 26 次全部拦住：大纲合同三轮修订后拒绝生成 6 次；发布门拒绝 14 次，其中履约终审不满足 13 次、屏级判错 8 次、练习屏被判不可操作 2 次、全课事实终审 1 次（一次拒绝可含多条原因）；基础设施失败 6 次（证据为空 3 次、检索桥异常 1 次、模型服务连接中断 2 次）。判词结构在协议修订前一次通过率为 0（两位判官各两次全被结构校验拒绝），协议改为「拒绝原因回喂 + 分段逐字锚点」后，最后一跑两位判官判词一次成型且一致判履约通过。最后一跑（17:01 起，人工智能域）被拦的唯一原因是全课事实终审发现一处跨屏不一致：测验把智能体四要素写成”感知、规划、行动、记忆”，教材与前两屏写的是”环境、传感器、执行器、自主性”。这是一处真实的内容错误，门禁把它拦住是正确结果；它随后进入人工复核出口。大纲阶段拒绝率 6/26（三轮修订后仍不合格），拒绝原因依次是：教学策略证据排不出顺序（改为确定性降级后不再出现）、迁移屏漏挂目标、目标动作写成动手程序而课程没有动手载体、前置激活屏一屏兼四目标。逐屏证据覆盖预检上线后没有再出现过”生成到 40% 才被屏级证据闸击杀”的情况。

（表 5-2：AI 与智能制造两门课的教学形态合同逐项结果。证据来源：最终生产课程、履约终审判词与实际错误作答补救记录。）

5.8 知识接入、项目发布与恢复验收

选一份可公开核验的领域资料，从上传开始记录全部阶段事件，检查阶段依赖，故意制造一次可恢复失败并确认后续阶段不会错误亮灯；任务完成后验证旧运行标记已清理、队列拒绝没有遗留收件文件、事件中的任务标识与当前任务一致。再从该课程生成实操项目草稿，检查所有仓库都能在候选接口结果中找到；发布第一版后修改步骤并发布第二版，执行一次恢复，确认恢复产生新版本且历史快照和哈希未被覆盖。外部接口不可用时页面应显示真实失败，不出现模型编造的替代仓库。

实际验收到的部分：工业时序数据库（IoTDB）语料一次接入 167 个文件、切出 2716 个证据块、按范围排除 30 个文件、退回 45 个正文不足 200 字符的占位文件，接入记录时间 2026 年 8 月 24 日 04:39（UTC），五站中四站有处理结果，向量索引已建。实操项目起草与勾选发布在 8 月下旬跑通过一版（4 个项目上线，见第 4 章截图），定稿时两套环境的发布记录已随语料重建清空；「发布第二版后恢复第一版」这一步没有做过，本文不声称已验证。

5.9 证据包的完整形态与变更控制

赛题要求至少两组差异学习者的完整输入、中间过程和输出。证据包对每组保存知识库版本与领域金标、学习者先验、课程目标、检索来源、生成场景、双审核意见、修订或仲裁、最终课程、作答记录、状态变化、路径、补救资源和报告；只截页面会丢失协同决策证据，只导出日志又证明不了用户实际可用。第三组差异画像要在先验、目标或掌握证据上形成可验差异，不是复制同一课程后改姓名。提交包 03-测试数据 里的第三组「零基础型」画像五项自评全为 0、目标是完成一个文档问答助手、约束为避免术语与需要可视化轨迹；与第一组「后端转智能体」和第二组「会 Python 不会智能体」在先验和目标上都不同，三组各自带输入画像、协同决策中间数据与最终资源三个文件，以画像 id 与检索块 source_id 互相对应。

生产验收不是录屏当天的临时状态。评测开始前冻结知识库文件、领域金标、学习者画像、课程目标、提示与结构版本、模型配置和代码提交并生成哈希；每次生成保存输入、检索片段、结构化输出、失败与重试、中间与最终课程和审核证明，指标异常时才能定位到检索、生成、审核还是统计环节。汇总表的每个分子都能反查样本编号，争议样本保留两名判定者的原始意见和最终裁决。若评测后修改了知识库、教学合同、模型或门禁，原结果必须标记失效或重新运行。验收报告列出未执行、失败和受外部服务影响的项目，不只收录通过项。本文对应的发布：Git 提交

6c4b810e74545aad215c3fc1f17b68be5c0d47c1（其前一版 8e462c7 于同日 16:05 UTC 上

线)，发布标识 6c4b810e74545aad215c3fc1f17b68be5c0d47c1-c61587b47d0c，构建标识 sDoj2evxn9QZ-GXVmSd3s，2026 年 9 月 2 日 17:40（UTC）经不可变发布脚本切换上线，冒烟检查（健康接口、首页、认证接口、机构管理页、公开课程列表与一门公开课页面）全部返回 200，两个服务以非 root 用户运行；生产只读验收报告存于提交包 docs/06-defense/evidence/production-node-report-readonly-20260902.json。

5.10 当前边界与仍需验证的部分

第一，最终代码仍需发布到服务器并完成同一版本的全链路验收。本文描述的教学履约终审、两级修订环、大纲证据预检和权限细节属于当前实现，不提前写成线上已通过。

第二，岗位数据只覆盖主域。切到非人工智能领域后岗位技能图谱为空态，这不影响该域的课程生成、学习路径与实操项目；处置是空态如实提示，岗位清单可随建库投料，格式校验从严，不合格拒收而非静默丢弃。

第三，学习增益验证停留在模型模拟，目前能严格证明的是资源生产、行为适配和系统边界，不是长期学习成效。第四，先修图中未经人工复核的边只是路径建议，判对率 47% 已写在 4.6 节；路径本身只按掌握证据移动游标，不重排概念顺序。第五，系统尚无机构级聚合学情看板，没做的不冒充做了。第六，异构双审、断言证据和人工校准能降低共同模型偏差的风险，不能把错误概率归零，植错实验里数值类错误的检出率就是这个盲区的量化表达。第七，课程资源质量受输入资料质量约束，知识库缺少关键内容时正确的输出是标记覆盖缺口并要求补充，这也是 4.5 节把证据覆盖预检前移到大纲阶段的原因。

第六章 逐条回应赛题与完成口径

6.1 逐条对照

输入与垂直领域。 系统以账户下的学习档案、一句学习目标、多维行为自评和同领域作答证据作为学习者输入，以机构公共或私有语料作为知识输入。人工智能应用开发是主验证领域，智能制造用于迁移验收；领域必须走完接入流水线并完成个性化注册，缺失时明确报告，不回退到默认领域。

协同闭环。 诊断、检索、生成、审核、仲裁、反馈决策和路径规划七类职责由有向状态图控制回流：审核失败触发定向修订或停止，分歧进入仲裁，作答反馈更新状态后重新检索、生成、审核和规划。协同的真实性由生成轨迹中的引擎标注承担，有效性由 5.3 节的三组实验承担，包括那一组没有增益的。

资源与报告。 系统输出结构化讲义、分层测验及补救练习、可执行实操指南、互动教具四种形态，超过题目规定的三种。学情报告包含当前领域的知识盲点、难度与掌握证据、路径节点及其来源；无证据时显示尚未测量。

动态调整。 真实作答绑定到题目、目标和概念，反馈角色选择继续、巩固、补救或提高挑战。错题补救只使用同一知识库证据并重新过审，掌握充分时安排迁移任务；导学角色通过追问支持学习者，不绕过证据给出知识库外结论。

幻觉治理与安全。 来源标识、断言级三值判定、跨厂商异构双审、两级定向修订、仲裁和全课终审串成一条链；审核记录缺失时不显示通过，课程变化后旧证明失效；被拦截的课程只有机构所有者复核后才对学习者可可见，谁放行、何时放行有据可查。机构归属在检索前控制，敏感操作验证身份并按失败关闭。正式幻觉率只采用冻结评测与可复算报告，检测器的外部校准结果如实写在 2.5 节，不包装成通过。

提交与可复现。 提交包包含技术文档、演示视频、源代码、部署说明、测试用例、至少一个垂直知识库，以及不少于两组差异学习者的完整输入、中间过程和输出；代码构建、部署版本、生产页面与指标报告必须对应同一发布。

6.2 四条原则与完成结论的条件

系统真正独特的地方不是某一项技术名，而是四条被实践逼出来的原则，每条都绑着一个真实产品行为和一份验证证据。证据先于生成：模型能写什么由检索决定，对应零证据需求被拦截的反向对照。判定先于交付：每条断言有判定记录，判不下的挂风险标识原样呈现，对应断言级审核账单。行为先于声明：功能以线上可验证的行为为准，消融无增益照实写，对应 5.3 节那组 88.7% 对 88.8% 的记录。缺失如实返回：岗位空态、未测量状态、拒绝发布都是有效结果，对应 4.8 节写下的那条纪律。

从代码结构看，系统已经形成题目所需的课程生产、协同审核、动态反馈、路径规划、机构隔离和隐私边界。是否达到最终完成，取决于同一发布版本能否通过第五章的全部生产验收，尤其是双机构跨领域链路、两门课教学履约合同、真实错题补救和三项核心指标的同版本重跑。未通过的项目将在最终材料中保留为缺口，不以局部测试或旧数据替代。后续工作只列与当前边界直接相连的三项：真人学习增益实验、机构级学情看板、岗位投料的格式规范与校验。我们对这道题的回答收在一句话上：企业的私有知识，能否安全地长成自己员工的课。

参考文献

[1] YU J F, ZHANG-LI D, ZHANG Z Y, et al. From MOOC to MAIC: Reimagine Online Teaching and Learning Through LLM-Driven Agents[J]. Journal of Computer Science and Technology, 2026, 41(1): 394-414. DOI: <https://doi.org/10.1007/s11390-025-6000-0>.

[2] ZHENG Y, HUANG S, ZENG X, et al. Knowledge-enhanced large language models for automatic lesson plan generation[J]. Humanities and Social Sciences Communications, 2025, 12: 1784. DOI: <https://doi.org/10.1057/s41599-025-06004-2>.

[3] WANG T, ZHAN Y, LIAN J, et al. LLM-powered Multi-agent Framework for Goal-oriented Learning in Intelligent Tutoring System[C]//Companion Proceedings of the ACM on Web Conference 2025. New York: ACM, 2025: 510–519. DOI: <https://doi.org/10.1145/3701716.3715244>.

[4] CORBETT A T, ANDERSON J R. Knowledge tracing: Modeling the acquisition of procedural knowledge[J]. User Modeling and User-Adapted Interaction, 1994, 4(4): 253–278. DOI: <https://doi.org/10.1007/BF01099821>.

[5] TONG S, LIU J, HONG Y, et al. Incremental Cognitive Diagnosis for Intelligent Education[C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM, 2022: 1760–1770. DOI: <https://doi.org/10.1145/3534678.3539399>.

[6] DU Y, LI S, TORRALBA A, et al. Improving Factuality and Reasoning in Language Models through Multiagent Debate[C/OL]//Proceedings of the 41st International Conference on Machine Learning. [S.l.]: PMLR, 2024, 235: 11733–11763[2026-09-01]. <https://proceedings.mlr.press/v235/du24e.html>. arXiv: 2305.14325.

[7] SMIT A P, GRINSZTAJN N, DUCKWORTH P, et al. Should we be going MAD? A Look at Multi-Agent Debate Strategies for LLMs[C/OL]//Proceedings of the 41st International Conference on Machine Learning. [S.l.]: PMLR, 2024, 235: 45883–

45905[2026-09-01]. <https://proceedings.mlr.press/v235/smit24a.html>. arXiv: 2311.17371.

[8] NIU C, WU Y, ZHU J, et al. RAGTruth: A Hallucination Corpus for Developing Trustworthy Retrieval-Augmented Language Models[C]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Bangkok: Association for Computational Linguistics, 2024: 10862–10878. DOI: <https://doi.org/10.18653/v1/2024.acl-long.585>.

[9] SAAD-FALCON J, KHATTAB O, POTTS C, et al. ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). Mexico City: Association for Computational Linguistics, 2024: 338–354. DOI: <https://doi.org/10.18653/v1/2024.naacl-long.20>.

[10] MISHRA A, ASAI A, BALACHANDRAN V, WANG Y, NEUBIG G, TSVETKOV Y, HAJISHIRZI H. Fine-grained Hallucination Detection and Editing for Language Models[EB/OL]. arXiv: 2401.06855v4, 2024[2026-09-02]. <https://arxiv.org/abs/2401.06855>.

[11] LIU X, YANG X, LI Z, LI P, HE R. AgentHallu: Benchmarking Automated Hallucination Attribution of LLM-based Agents[EB/OL]. arXiv: 2601.06818, 2026[2026-09-02]. <https://arxiv.org/abs/2601.06818>.

附录 A 图表制作口径

正文规划十处图位、三处表位，另有 5.1 节的指标对照表。架构图、状态图和流程图按代码中的真实节点与依赖重绘，不使用无法辨认的全景截图；用户流程图采用生产页面局部截图并保留角色、领域和状态。表格注明版本、时间、样本、分子、分母和证据路径；图中不出现真实账户、会话令牌、服务器密钥和未脱敏课程标识；生产证据未取得的图表保留缺口说明。图题置下、表题置上，按章编号，正文先引用后出现。